


# **FUNDAMENTOS DE LA BIOESTADISTICA DESCRIPTIVA EN R**

PROF. ASTRID LILIANA VARGAS SANCHEZ  
M.S.C EN BIOINFORMÁTICA  
UNIVERSIDAD INTERNACIONAL DE LA RIOJA



# CUÉNTAME SOBRE TI

¿DE DONDE ERES?

¿QUE NIVEL DE ESTUDIOS TIENES?

¿TIENES CONOCIMIENTOS DE  
BIOESTADÍSTICA?

¿TIENES CONOCIMIENTOS DE  
PROGRAMACIÓN?



MODULO 1

# INTRODUCCIÓN A R PARA BIOESTADISTICA

# LENGUAJE DE PROGRAMACIÓN R



- Lenguaje de programación para análisis estadístico y visualización.
- Fue creado por Ross Ihaka y Robert Gentleman en 1996.
- Popular en bioestadística, bioinformática y ciencia de datos.
- Es software libre y gratuito
- Línea de comandos
- Se puede utilizar sin RStudio

# INSTALACIÓN DE R

Descarga desde <https://cran.r-project.org/>



*CRAN*  
[Mirrors](#)  
[What's new?](#)  
[Search](#)  
[CRAN Team](#)

*About R*  
[R Homepage](#)  
[The R Journal](#)

*Software*  
[R Sources](#)  
[R Binaries](#)  
[Packages](#)  
[Task Views](#)  
[Other](#)

*Documentation*  
[Manuals](#)  
[FAQs](#)  
[Contributed](#)

*Donations*  
[Donate](#)

The Comprehensive R Archive Network

Download and Install R

Precompiled binary distributions of the base system and contributed packages, **Windows and Mac** users most likely want one of these versions of R:

- [Download R for Linux \(Debian, Fedora/Redhat, Ubuntu\)](#)
- [Download R for macOS](#)
- [Download R for Windows](#)

R is part of many Linux distributions, you should check with your Linux package management system in addition to the link above.

Source Code for all Platforms

Windows and Mac users most likely want to download the precompiled binaries listed in the upper box, not the source code. The sources have to be compiled before you can use them. If you do not know what this means, you probably do not want to do it!

- The latest release (2025-04-11, How About a Twenty-Six) [R-4.5.0.tar.gz](#), read [what's new](#) in the latest version.
- The CRAN directory [src/base-prerelease](#) contains R alpha, beta, and rc releases as daily snapshots in time periods before a planned release.
- Between releases, the same directory [src/base-prerelease](#) contains snapshots of current patched and development versions. Please read about [new features and bug fixes](#) before filing corresponding feature requests or bug reports.
- Alternatively, daily snapshots are [available here](#).
- Source code of older versions of R is [available here](#).
- Contributed extension [packages](#).

Questions About R

- If you have questions about R like how to download and install the software, or what the license terms are, please read our [answers to frequently asked questions](#) before you send an email.

Supporting CRAN

- CRAN operations, most importantly hosting, checking, distributing, and archiving of R add-on packages for various platforms, crucially rely on technical, emotional, and financial support by the R community.

Please consider making [financial contributions](#) to the R Foundation for Statistical Computing.

What are R and CRAN?

R is 'GNU S', a freely available language and environment for statistical computing and graphics which provides a wide variety of statistical and graphical techniques: linear and nonlinear modelling, statistical tests, time series



# R STUDIO (POSIT RSTUDIO)



- Entorno de desarrollo integrado (IDE).
- Interfaz amigable que facilita la escritura de código, la visualización de gráficos, la administración de proyectos y la depuración de scripts.
- Mejora la experiencia de programación en R, pero no es un lenguaje en sí mismo.
- Incluye una consola, un editor de scripts, un visor de gráficos y pestañas para explorar variables, archivos y paquetes.

# INSTALACIÓN DE R STUDIO

Descarga desde: <https://posit.co/download/rstudio-desktop/>

 PRODUCTS ▾ OPEN SOURCE ▾ USE CASES ▾ PARTNERS ▾ LEARN & SUPPORT ▾ ABOUT ▾

DOWNLOAD

## RStudio Desktop

Used by millions of people weekly, the RStudio integrated development environment (IDE) is a set of tools built to help you be more productive with R and Python.

Don't want to download or install anything? Get started with RStudio on [Posit Cloud for free](#). If you're a professional data scientist looking to download RStudio and also need common enterprise features, don't hesitate to [book a call with us](#).

Want to learn about core or advanced workflows in RStudio? Explore the [RStudio User Guide](#) or the [Getting Started](#) section.

### 1: Install R

RStudio requires R 3.6.0+. Choose a version of R that matches your computer's operating system.

*R is not a Posit product. By clicking on the link below to download and install R, you are leaving the Posit website.*

### 2: Install RStudio

DOWNLOAD RSTUDIO DESKTOP FOR WINDOWS



Size: 281.27 MB | [SHA-256: 9E6F68CA](#) | Version: 2025.05.0+496 |  
Released: 2025-05-05



Cómo instalar R y RStudio en menos de 2 minutos - 2025



Copy link



# COMO INSTALAR R Y RSTUDIO 2025



Watch on  YouTube


<https://www.youtube.com/watch?v=hbgzW3Cvda4>





Material del curso:

Link: [https://github.com/Liliana223/Fundamentos-de-la-bioestadistica-descriptiva?utm\\_source=canva&utm\\_medium=iframe](https://github.com/Liliana223/Fundamentos-de-la-bioestadistica-descriptiva?utm_source=canva&utm_medium=iframe)



# VARIABLES

Una variable es un espacio de memoria al que accedemos mediante un identificador.

Una variable permite asociar un valor u objeto a un identificador. En la memoria del ordenador habrá una zona donde se almacena el objeto asociado a la variable

|           |                                                                     |       |                            |
|-----------|---------------------------------------------------------------------|-------|----------------------------|
| Integer   | Números enteros (1, 5, -5, 8, -23). Se debe asignar con la letra L. | Date  | Fecha (día, mes y año)     |
| Numeric   | Números con decimales (3,2; -6,32; 4,12)                            | POSIX | Fecha, hora y huso horario |
| Logical   | Datos booleanos: True o false.                                      | NA    | Valor no disponible        |
| Character | Texto                                                               | NULL  | Elemento vacío             |
| Factor    | Información categórica                                              | Inf   | Infinito                   |

# TIPOS DE VARIABLES

Variables cualitativas (categóricas) : Estas no se expresan con números. Representan cualidades, atributos o categorías.

Variables cuantitativas (numéricas): Son aquellas que se expresan con números y permiten hacer operaciones matemáticas.

**Nominales**  
No tienen un orden lógico.  
Solo identifican o clasifican.

Ejemplo: Género: femenino, masculino, no binario.

**Ordinales**  
Sí tienen un orden lógico, pero sin una distancia numérica clara entre categorías.

Ejemplo: Puesto en una competencia: 1.º, 2.º, 3.º.

**Discretas**  
Toman valores enteros y contables. No tienen decimales.

Ejemplo: Número de hijos.

**Continuas**  
Toman valores infinitos dentro de un intervalo, incluyen decimales. Se obtienen mediante medición.

Ejemplo: Peso (62.3 kg).

# OPERADORES


Un operador es un símbolo o conjunto de símbolos que indica a R que debe realizar una operación específica sobre uno o más valores (llamados operandos)

| Tipo de Operador | Operador(es) | Descripción                                                               | Ejemplo              |
|------------------|--------------|---------------------------------------------------------------------------|----------------------|
| Aritméticos      | +, -, *, /   | Suma, resta, multiplicación, división                                     | 2 + 3 → 5            |
|                  | ^            | Potencia                                                                  | 2^3 → 8              |
|                  | %%           | Resto de dividir un número por otro                                       | 10 %% 3 → 1          |
|                  | %/%          | División entera                                                           | 10 %/% 3 → 3         |
| Comparativos     | ==, !=       | Igualdad, diferente                                                       | 5 == 5 → TRUE        |
|                  | <, >, <=, >= | Comparaciones                                                             | 4 <= 3 → FALSE       |
| Lógicos          | &            | Sentencia AND. Ambos elementos deben ser TRUE para que se obtenga TRUE    | TRUE & FALSE → FALSE |
|                  |              | Sentencia OR. Al menos un elemento debe ser TRUE para que se obtenga TRUE | TRUE   FALSE → TRUE  |
|                  | !            | Se invierte el dato booleano                                              | !TRUE → FALSE        |
| Asignación       | <-, ->, =    | Asignación de valores                                                     | x <- 10              |
| Secuencia        | :            | Secuencia de números                                                      | 1:5 → 1 2 3 4 5      |

# ARRAY

- Permite almacenar múltiples valores del mismo tipo en una sola variable, en lugar de declarar variables individuales para cada valor.
- Es una colección ordenada de elementos.
- Todos los elementos del array son del mismo tipo de dato (por ejemplo, enteros, cadenas, booleanos).
- Es posible el acceso a cada elemento de un array a través de un número entero que se denomina índice.
- La numeración de estos elementos dentro del array comienza en 0 (primer elemento del array) y finaliza en  $n-1$  (último elemento del array) donde  $n$  es el tamaño completo de dicho array (Python, C, y JavaScript).
- En R la numeración de estos elementos dentro del array comienza en 1 (primer elemento del array) y finaliza en  $n-1$  (último elemento del array) donde  $n$  es el tamaño completo de dicho array


## Array Data Structure






# ESTRUCTURAS DE DATOS EN R


Vector




Matrix



Array



Data frame




Columns can be different modes

List

Vectors  
Arrays  
Data frames  
Lists

# ESTRUCTURAS DE DATOS EN R




## VECTOR

Array de una única  
dimensión que almacena  
datos del mismo tipo.

# ESTRUCTURAS DE DATOS EN R

Matrix




## MATRIZ

Objeto de dos dimensiones  
con formato tabla (Con filas  
y columnas) con elementos  
del mismo tipo.



# ESTRUCTURAS DE DATOS EN R

## Data frame




## DATA FRAME

Objeto de dos dimensiones con formato tabla (Con filas y columnas) con elementos diferentes. Las filas en un data frame representan casos, individuos u observaciones, mientras que las columnas representan atributos, rasgos o variables. Las columnas deben tener la misma longitud

# ESTRUCTURAS DE DATOS EN R

Array



## ARRAY

Estructura que tiene mas de dos dimensiones con elementos del mismo tipo.

Pueden ser cubos, hipercubos y otras formas.

Su uso no es muy común en R.

# ESTRUCTURAS DE DATOS EN R

List

Vectors

Arrays

Data frames

Lists

## LISTAS

Son estructuras que pueden contener elementos de diferentes tipos y estructuras: vectores, matrices, otros data frames o listas.

# FUNCIÓN

Una función en R es un bloque de código reutilizable que realiza una o mas tareas de forma secuencial, nos permite organizar y automatizar procesos repetitivos. Puede tomar uno o más argumentos como entrada, ejecutar un conjunto de instrucciones, y devolver un resultado como salida.

`print()`

Toma como parámetro una expresión y muestra en la salida el resultado de evaluar la expresión.

`length()`

Devuelve el numero de elementos

# PAQUETES O LIBRERIAS

Es un conjunto organizado de funciones y/o datos que han sido desarrollados para realizar tareas específicas, como análisis estadísticos, visualización de datos, manipulación de datos, etc. Permiten reutilizar código y facilitan tareas complejas sin tener que programar todo desde cero.





# TIDYVERSE

Es un conjunto de paquetes en R diseñados para trabajar de forma coherente con datos "ordenados" (tidy data), facilitando tareas como importar, transformar, visualizar y modelar datos.



Tidyverse packages: <https://www.tidyverse.org/packages/>

| Paquete | Función principal                                     | Uso típico                               |
|---------|-------------------------------------------------------|------------------------------------------|
| ggplot2 | Visualización de datos con una gramática de gráficos. | Crear gráficos personalizados.           |
| dplyr   | Manipulación y transformación de datos.               | Filtrar, seleccionar, agrupar, resumir.  |
| tidyr   | Organización de datos en formato ordenado (tidy).     | Separar, unir, pivotear columnas.        |
| readr   | Importación rápida y limpia de datos desde archivos.  | Leer CSV, TXT, TSV, etc.                 |
| tibble  | Estructura moderna de data frames.                    | Imprime datos de forma clara y legible.  |
| purrr   | Programación funcional con listas y vectores.         | Aplicar funciones a múltiples elementos. |
| stringr | Manipulación de texto (strings).                      | Buscar, reemplazar o modificar texto.    |
| forcats | Manejo de factores (variables categóricas).           | Reordenar o recodificar categorías.      |

[https://diegokoz.github.io/intro\\_ds/fuentes/ggplot2-cheatsheet-2.1-Spanish.pdf](https://diegokoz.github.io/intro_ds/fuentes/ggplot2-cheatsheet-2.1-Spanish.pdf)


```
install.packages("ggplot2")  
library(ggplot2)
```

## Visualización de Datos usando ggplot2 Guía Rápida




### Conceptos Básicos

ggplot2 se basa en la idea que cualquier gráfica se puede construir usando estos tres componentes: **datos**, **coordenadas** y **objetos geométricos (geoms)**. Este concepto se llama **gramática de las gráficas**.



Para visualizar resultados, asigne variables a las propiedades visuales, o **estéticas**, como **tamaño**, **color** y **posición x** o **y**.



Para construir una gráfica complete este patrón

```
ggplot(data = «DATOS») +  
  «FUNCIÓN_GEOM» (  
    mapping = aes(«ESTÉTICAS»),  
    stat = «STAT»,  
    position = «POSICIÓN»  
  ) +  
  «FUNCIÓN_COORDINADAS» +  
  «FUNCIÓN_FACETA» +  
  «FUNCIÓN_ESCALA» +  
  «FUNCIÓN_TEMA»
```

Requerido  
No  
Requerido,  
se proveen  
valores  
iniciales

`ggplot(data = mpg, aes(x = cty, y = hwy))`  
Este comando comienza una gráfica, complétala mediante agregando capas, un **geom** por capa.

`qplot(x = cty, y = hwy, data = mpg, geom = "point")`  
Este comando es una gráfica completa, tiene datos, las estéticas están asignadas y por lo menos un geom.

`last_plot()`  
Devuelve la última gráfica

`ggsave("plot.png", width = 5, height = 5)`  
La última gráfica es grabada como una imagen de 5 por 5 pulgs., usa el mismo tipo de archivo que la extensión

## Geoms - Funciones geom se utilizan para visualizar resultados. Asigne variables a las propiedades estéticas del geom. Cada geom forma una capa.

### Geométricas Elementales

```
a <- ggplot(economics, aes(date, unemploy))  
b <- ggplot(seals, aes(x = long, y = lat))
```

- `a + geom_blank()`  
(Bueno para expandir límites)
- `b + geom_curve(aes(yend = lat + 1, xend = long + 1, curvature = z))` - x, xend, y, yend, alpha, angle, color, curvature, linetype, size
- `a + geom_path(lineend = "butt", linejoin = "round", linemitre = 1)` - x, y, alpha, color, group, linetype, size
- `a + geom_polygon(aes(group = group))` - x, y, alpha, color, fill, group, linetype, size
- `b + geom_rect(aes(xmin = long, ymin = lat, xmax = long + 1, ymax = lat + 1))` - xmin, xmax, ymin, ymax, alpha, color, fill, linetype, size
- `a + geom_ribbon(aes(ymin = unemploy - 900, ymax = unemploy + 900))` - x, ymax, ymin, alpha, color, fill, group, linetype, size

### Segmentos Lineales

- propiedades básicas: x, y, alpha, color, linetype, size
- `b + geom_abline(aes(intercept = 0, slope = 1))`
  - `b + geom_hline(aes(yintercept = lat))`
  - `b + geom_vline(aes(xintercept = long))`
  - `b + geom_segment(aes(yend = lat + 1, xend = long + 1))`
  - `b + geom_spoke(aes(angle = 1:1155, radius = 1))`

### Una Variable

#### Continua

- ```
c <- ggplot(mpg, aes(hwy)); c2 <- ggplot(mpg)
```
- `c + geom_area(stat = "bin")` - x, y, alpha, color, fill, linetype, size
  - `c + geom_density(kernel = "gaussian")` - x, y, alpha, color, fill, group, linetype, size, weight
  - `c + geom_dotplot()` - x, y, alpha, color, fill
  - `c + geom_freqpoly()` - x, y, alpha, color, group, linetype, size
  - `c + geom_histogram(binwidth = 5)` - x, y, alpha, color, fill, linetype, size, weight
  - `c2 + geom_qq(aes(sample = hwy))` - x, y, alpha, color, fill, linetype, size, weight

#### Discreta

- ```
d <- ggplot(mpg, aes(fill))
```
- `d + geom_bar()` - x, alpha, color, fill, linetype, size, weight

### Dos Variables

#### X Continua, Y Continua

```
e <- ggplot(mpg, aes(cty, hwy))
```

- `e + geom_label(aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE)` - x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust
- `e + geom_jitter(height = 2, width = 2)` - x, y, alpha, color, fill, shape, size
- `e + geom_point()` - x, y, alpha, color, fill, shape, size, stroke
- `e + geom_quantile()` - x, y, alpha, color, group, linetype, size, weight
- `e + geom_rug(sides = "bl")` - x, y, alpha, color, linetype, size
- `e + geom_smooth(method = lm)` - x, y, alpha, color, fill, group, linetype, size, weight
- `e + geom_text(aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE)` - x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

#### X Discreta, Y Continua

```
f <- ggplot(mpg, aes(class, hwy))
```

- `f + geom_col()` - x, y, alpha, color, fill, group, linetype, size
- `f + geom_boxplot()` - x, y, lower, middle, upper, ymax, ymin, alpha, color, fill, group, linetype, shape, size, weight
- `f + geom_dotplot(binaxis = "y", stackdir = "center")` - x, y, alpha, color, fill, group
- `f + geom_violin(scale = "area")` - x, y, alpha, color, fill, group, linetype, size, weight

#### X Discreta, Y Discreta

```
g <- ggplot(diamonds, aes(cut, color))
```

- `g + geom_count()` - x, y, alpha, color, fill, shape, size, stroke

#### Distribución Bivariada Continua

```
h <- ggplot(diamonds, aes(carat, price))
```

- `h + geom_bin2d(binwidth = c(0.25, 500))` - x, y, alpha, color, fill, linetype, size, weight
- `h + geom_density2d()` - x, y, alpha, colour, group, linetype, size
- `h + geom_hex()` - x, y, alpha, colour, fill, size

### Función Continua

```
i <- ggplot(economics, aes(date, unemploy))
```

- `i + geom_area()` - x, y, alpha, color, fill, linetype, size
- `i + geom_line()` - x, y, alpha, color, group, linetype, size
- `i + geom_step(direction = "hv")` - x, y, alpha, color, group, linetype, size

### Visualizando el Error

```
df <- data.frame(grp = c("A", "B"), fit = 4:5, se = 1:2)  
j <- ggplot(df, aes(grp, fit, ymin = fit-se, ymax = fit+se))
```

- `j + geom_crossbar(fatten = 2)` - x, y, ymax, ymin, alpha, color, fill, group, linetype, size
- `j + geom_errorbar()` - x, ymax, ymin, alpha, color, group, linetype, size, width (also `geom_errorbarh()`)
- `j + geom_linerange()` - x, ymin, ymax, alpha, color, group, linetype, size
- `j + geom_pointrange()` - x, y, ymin, ymax, alpha, color, fill, group, linetype, shape, size

### Mapas

```
data <- data.frame(murder = USArrests$Murder,  
  state = tolower(rownames(USArrests)))  
map <- map_data("state")  
k <- ggplot(data, aes(fill = murder))
```

- `k + geom_map(aes(map_id = state), map = map) + expand_limits(x = map$long, y = map$lat)` - map\_id, alpha, color, fill, linetype, size

### Trés Variables

```
sealsSz <- with(seals, sqrt(delta_long*2 + delta_lat*2))  
l <- ggplot(seals, aes(long, lat))
```

- `l + geom_contour(aes(z = z))` - x, y, z, alpha, colour, group, linetype, size, weight

```
l + geom_raster(aes(fill = z),  
  hjust=0.5, vjust=0.5,  
  interpolate=FALSE)
```

- `l + geom_tile(aes(fill = z))` - x, y, alpha, color, fill, linetype, size, width

### Argumentos


Traducción de argumentos comunes  
label = etiqueta, angle = ángulo  
size = tamaño, weight = peso  
alpha = transparencia  
fontface = tipo de letra  
hjust = ajuste horizontal  
lineheight = grosor de línea



# DATSET IRIS

| Nombre original | Traducción                     | Explicación adicional                              |
|-----------------|--------------------------------|----------------------------------------------------|
| Sepal.Length    | Longitud.Sépalo o Largo.Sépalo | Longitud del sépalo en centímetros                 |
| Sepal.Width     | Ancho.Sépalo                   | Ancho del sépalo en centímetros                    |
| Petal.Length    | Longitud.Pétalo o Largo.Pétalo | Longitud del pétalo en centímetros                 |
| Petal.Width     | Ancho.Pétalo                   | Ancho del pétalo en centímetros                    |
| Species         | Especie                        | Especie de la flor (Setosa, Versicolor, Virginica) |


Otros dataset para practicar: <https://www.kaggle.com/datasets>





## MODULO 2

# FUNDAMENTOS DE LA BIOESTADISTICA DESCRIPTIVA



# BIOESTADISTICA

Rama de la estadística que recopila, organiza, procesa e interpreta datos para deducir características de un grupo. Se aplica al estudio de los seres vivos, especialmente en las áreas de la medicina, la biología, la salud pública y las ciencias de la vida.

Bioestadística  
descriptiva

Bioestadística  
inferencial

# BIOESTADÍSTICA DESCRIPTIVA

Se encarga de resumir y describir los datos mediante medidas numéricas (como promedios, medianas y desviaciones estándar) y representaciones gráficas (como tablas, gráficos de barras o histogramas). Su objetivo es organizar y presentar la información de forma comprensible, sin realizar inferencias o predicciones. Información acerca de la distribución, dispersión y forma de los datos.


# MUESTRA

Es un subconjunto representativo de una población que se selecciona para estudiar y obtener conclusiones sobre esa población sin tener que analizar a todos sus integrantes con el objetivo de estudiar sus características y hacer inferencias o generalizaciones sobre toda la población. La elección de una muestra adecuada es crucial en el análisis estadístico, ya que una muestra inadecuada puede llevar a conclusiones erróneas o sesgadas.





# CAMPANA DE GAUSS




Es una representación gráfica de la distribución normal. Los datos están simétricamente distribuidos alrededor de la media. Cuanto más te alejas de la media, menos frecuencia tienen los valores.



Material del curso:


Link: [https://github.com/Liliana223/Fundamentos-de-la-bioestadistica-descriptiva?utm\\_source=canva&utm\\_medium=iframe](https://github.com/Liliana223/Fundamentos-de-la-bioestadistica-descriptiva?utm_source=canva&utm_medium=iframe)



# DATSET IRIS

| Nombre original | Traducción                     | Explicación adicional                              |
|-----------------|--------------------------------|----------------------------------------------------|
| Sepal.Length    | Longitud.Sépalo o Largo.Sépalo | Longitud del sépalo en centímetros                 |
| Sepal.Width     | Ancho.Sépalo                   | Ancho del sépalo en centímetros                    |
| Petal.Length    | Longitud.Pétalo o Largo.Pétalo | Longitud del pétalo en centímetros                 |
| Petal.Width     | Ancho.Pétalo                   | Ancho del pétalo en centímetros                    |
| Species         | Especie                        | Especie de la flor (Setosa, Versicolor, Virginica) |

Otros dataset para practicar: <https://www.kaggle.com/datasets>





## Visualización de Datos


### usando ggplot2

#### Guía Rápida




### Conceptos Básicos

ggplot2 se basa en la idea que cualquier gráfica se puede construir usando estos tres componentes: **datos**, **coordenadas** y **objetos geométricos (geoms)**. Este concepto se llama: **gramática de las gráficas**.



Para visualizar resultados, asigne variables a las propiedades visuales, o **estéticas**, como **tamaño**, **color** y **posición x ó y**.



Para construir una gráfica complete este patrón

```
ggplot(data = <DATOS>) +  
  <FUNCION_GEOM> (  
    mapping = aes() (<ESTETICAS>),  
    stat = <STAT>,  
    position = <POSICION>  
  ) +  
  <FUNCION_COORDINADAS> +  
  <FUNCION_FACETA> +  
  <FUNCION_ESCALA> +  
  <FUNCION_TEMA>
```

**Requerido**

No Requerido, se proveen valores iniciales

`ggplot(data = mpg, aes(x = cty, y = hwy))`

Este comando comienza una gráfica, complétela mediante agregando capas, un **geom** por capa.

estéticas      datos      geom

`qplot(x = cty, y = hwy, data = mpg, geom = "point")`  
Este comando es una gráfica completa, tiene datos, las estéticas están asignadas y por lo menos un geom.

`last_plot()`

Devuelve la última gráfica

`ggsave("plot.png", width = 5, height = 5)`

La última gráfica es grabada como una imagen de 5 por 5 pulgs., usa el mismo tipo de archivo que la extensión

### Geoms

Funciones geom se utilizan para visualizar resultados. Asigne variables a las propiedades estéticas del geom. Cada geom forma una capa.

#### Geométricas Elementales

`a <- ggplot(economics, aes(date, unemploy))`  
`b <- ggplot(seals, aes(x = long, y = lat))`



`a + geom_blank()`  
(Bueno para expandir límites)



`b + geom_curve(aes(yend = lat + 1,  
xend=long+1,curvature=z))` - x, xend, y, yend,  
alpha, angle, color, curvature, linetype, size



`a + geom_path(linetype="butt",  
linejoin="round", linemitre=1)`  
x, y, alpha, color, group, linetype, size



`a + geom_polygon(aes(group = group))`  
x, y, alpha, color, fill, group, linetype, size



`b + geom_rect(aes(xmin = long, ymin=lat,  
xmax=long + 1, ymax = lat + 1))` - xmax, xmin,  
ymax, ymin, alpha, color, fill, linetype, size



`a + geom_ribbon(aes(ymin=unemploy - 900,  
ymax=unemploy + 900))` - x, ymax, ymin  
alpha, color, fill, group, linetype, size

#### Segmentos Lineares

propiedades básicas: x, y, alpha, color, linetype, size



`b + geom_abline(aes(intercept=0, slope=1))`

`b + geom_hline(aes(yintercept = lat))`

`b + geom_vline(aes(xintercept = long))`



`b + geom_segment(aes(yend=lat+1, xend=long+1))`

`b + geom_spoke(aes(angle = 1:1155, radius = 1))`

#### Una Variable

##### Continua

`c <- ggplot(mpg, aes(hwy)); c2 <- ggplot(mpg)`



`c + geom_area(stat = "bin")`  
x, y, alpha, color, fill, linetype, size



`c + geom_density(kernel = "gaussian")`  
x, y, alpha, color, fill, group, linetype, size, weight



`c + geom_dotplot()`  
x, y, alpha, color, fill



`c + geom_freqpoly()`  
x, y, alpha, color, group, linetype, size



`c + geom_histogram(binwidth = 5)`  
x, y, alpha, color, fill, linetype, size, weight



`c2 + geom_qq(aes(sample = hwy))`  
x, y, alpha, color, fill, linetype, size, weight

##### Discreta



`d <- ggplot(mpg, aes(R))`  
`d + geom_bar()`  
x, alpha, color, fill, linetype, size, weight

#### Dos Variables

##### X Continua, Y Continua

`e <- ggplot(mpg, aes(cty, hwy))`



`e + geom_label(aes(label = cty), nudge_x = 1,  
nudge_y = 1, check_overlap = TRUE)`  
x, y, label, alpha, angle, color, family, fontface,  
hjust, lineheight, size, vjust



`e + geom_jitter(height = 2, width = 2)`  
x, y, alpha, color, fill, shape, size



`e + geom_point()`  
x, y, alpha, color, fill, shape, size, stroke



`e + geom_quantile()`  
x, y, alpha, color, group, linetype, size, weight



`e + geom_rug(sides = "bl")`  
x, y, alpha, color, linetype, size



`e + geom_smooth(method = lm)`  
x, y, alpha, color, fill, group, linetype, size, weight



`e + geom_text(aes(label = cty), nudge_x = 1,  
nudge_y = 1, check_overlap = TRUE)`  
x, y, label, alpha, angle, color, family, fontface,  
hjust, lineheight, size, vjust

##### X Discreta, Y Continua

`f <- ggplot(mpg, aes(class, hwy))`



`f + geom_col()`  
x, y, alpha, color, fill, group, linetype, size



`f + geom_boxplot()`  
x, y, lower, middle, upper, ymax, ymin, alpha,  
color, fill, group, linetype, shape, size, weight



`f + geom_dotplot(binaxis = "y",  
stackdir = "center")`  
x, y, alpha, color, fill, group



`f + geom_violin(scale = "area")`  
x, y, alpha, color, fill, group, linetype, size,  
weight

##### X Discreta, Y Discreta

`g <- ggplot(diamonds, aes(cut, color))`



`g + geom_count()`  
x, y, alpha, color, fill, shape, size, stroke

#### Trés Variables

`seals$z <- with(seals, sqrt(delta_long^2  
+ delta_lat^2))`



`l <- ggplot(seals, aes(long, lat))`  
`l + geom_raster(aes(fill = z),  
hjust=0.5, vjust=0.5,  
interpolate=FALSE)`  
x, y, alpha, fill



`l + geom_contour(aes(z = z))`  
x, y, z, alpha, colour, group,  
linetype, size, weight

##### Distribución Bivariada Continua

`h <- ggplot(diamonds, aes(carat, price))`



`h + geom_bin2d(binwidth = c(0.25, 500))`  
x, y, alpha, color, fill, linetype, size, weight



`h + geom_density2d()`  
x, y, alpha, colour, group, linetype, size



`h + geom_hex()`  
x, y, alpha, colour, fill, size

##### Función Continua

`i <- ggplot(economics, aes(date, unemploy))`



`i + geom_area()`  
x, y, alpha, color, fill, linetype, size



`i + geom_line()`  
x, y, alpha, color, group, linetype, size



`i + geom_step(direction = "hv")`  
x, y, alpha, color, group, linetype, size

##### Visualizando el Error

`df <- data.frame(grp = c("A", "B"), fit = 4:5, se = 1:2)`

`j <- ggplot(df, aes(grp, fit, ymin = fit-se, ymax = fit+se))`



`j + geom_crossbar(latten = 2)`  
x, y, ymax, ymin, alpha, color, fill, group,  
linetype, size



`j + geom_errorbar()`  
x, ymax, ymin, alpha, color, group, linetype,  
size, width (also `geom_errorbarh()`)



`j + geom_linerange()`  
x, ymin, ymax, alpha, color, group, linetype, size



`j + geom_pointrange()`  
x, y, ymin, ymax, alpha, color, fill, group,  
linetype, shape, size

##### Mapas

`data <- data.frame(murder = USArrests$Murder,  
state = tolower(rownames(USArrests)))`  
`map <- map_data("state")`  
`k <- ggplot(data, aes(fill = murder))`




`k + geom_map(aes(map_id = state), map = map) +  
expand_limits(x = map$long, y = map$lat)`  
map\_id, alpha, color, fill, linetype, size

#### Argumentos

Traducción de argumentos comunes


label = etiqueta, angle=ángulo  
size=tamaño, weight=peso  
alpha=transparencia  
fontface=tipo de letra  
hjust=ajuste horizontal  
lineheight=gresor de línea

# REPRESENTACIONES GRÁFICAS




## HISTOGRAMAS

Representa variables cuantitativas continuas. Distribución de frecuencia de un conjunto de datos numéricos continuos



## GRAFICOS DE BARRAS


Representa variables categóricas o discretas. El eje x representa las categorías y el eje y representa la frecuencia con la que aparecen esas categorías.



## DIAGRAMA DE PASTEL


Representa proporciones o porcentajes de categorías.

# REPRESENTACIONES GRÁFICAS



## DIAGRAMA DE DISPERSIÓN


Muestra la relación entre dos variables cuantitativas. Cada punto en el gráfico representa una observación.



## DIAGRAMA DE CAJA Y BIGOTES (BOXPLOT)

Resume la distribución de un conjunto de datos numéricos. Muestra la mediana, los cuartiles y posibles valores atípicos.

# REPRESENTACIONES GRÁFICAS



# MEDIDAS NUMÉRICAS

| Medidas de tendencia central | Medidas de dispersión    | Medidas de forma y posición |
|------------------------------|--------------------------|-----------------------------|
| Media                        | Rango                    | Asimetría                   |
| Mediana                      | Varianza                 | Curtosis                    |
| Moda                         | Desviación estándar      | Cuartiles                   |
|                              | Coeficiente de variación | Percentiles                 |



# MEDIDAS DE TENDENCIA CENTRAL


Valor que representa la posición central de una distribución de datos

## MEDIA

Es una medida estadística utilizada para obtener el valor promedio de un conjunto de datos. Es la suma de todos los valores dividida entre la cantidad de datos. Es sensible a datos atípicos.

$$m = \frac{\text{suma de los términos}}{\text{número de términos}}$$

# CAMPANA DE GAUSS



Es una representación gráfica de la distribución normal. Los datos están simétricamente distribuidos alrededor de la media. Cuanto más te alejas de la media, menos frecuencia tienen los valores.

# MEDIDAS DE TENDENCIA CENTRAL

## MEDIANA

Representa el valor central en un conjunto de datos ordenados. Reduce el impacto de los valores atípicos. Si hay un número par de datos, es el promedio de los dos valores centrales.

Ejemplo impar:

Datos: 3, 5, 7 → la mediana es 5

Ejemplo par:

Datos: 2, 4, 6, 8 → la mediana es  $(4+6)/2=5$



# MEDIDAS DE TENDENCIA CENTRAL


## MODA

La moda es un valor estadístico que representa el valor más frecuente o con un mayor número de apariciones en un conjunto de datos


Ejemplo:

Datos: 2, 3, 3, 4, 5 → la moda es 3


Asimetría Negativa



Normal (sin asimetría)



Asimetría Positiva



# MEDIDAS DE DISPERSIÓN

Son un conjunto de estadísticos que nos permiten conocer la variabilidad de los datos. nos indican qué tan dispersos o agrupados están los datos con respecto a la media o entre sí. Sirven para complementar a las medidas de tendencia central y entender mejor la distribución de los datos.

## RANGO

Es la diferencia entre el valor más grande (Valor máximo) y el más pequeño (Valor mínimo). Qué tan dispersos o extendidos están los datos?

$$R = x_{\text{máx}} - x_{\text{mín}}$$

# MEDIDAS DE DISPERSIÓN

## VARIANZA

Mide cuánto se alejan, en promedio, los datos con respecto a la media, elevando al cuadrado esas diferencias. Se mide en unidades al cuadrado, por ejemplo, si tus datos están en centímetros, la varianza estará en  $\text{cm}^2$ .

$$\text{Var}(X) = \frac{\sum_1^n (x_i - \bar{X})^2}{n}$$

Donde:

- $x_i$ : Cada dato
- $\bar{X}$ : La media
- $n$ : Número de datos

# MEDIDAS DE DISPERSIÓN

## DESVIACIÓN ESTANDAR

Es la raíz cuadrada de la varianza. Mide cuánto se desvían, en promedio, los datos con respecto a la media, pero en las mismas unidades del dato original.

$$\text{Desviación estándar} = \sqrt{\text{Varianza}}$$



# MEDIDAS DE DISPERSIÓN

## COEFICIENTE DE VARIACIÓN

Mide la dispersión en porcentaje respecto a la media. Se usa para comparar variabilidad entre distintos conjuntos de datos (aunque tengan unidades diferentes).

$$\text{Coeficiente de variación} = \left( \frac{\text{Desviación estándar}}{\text{Media}} \right) \times 100$$



# MEDIDAS DE FORMA Y POSICIÓN


Las medidas de forma y posición son herramientas estadísticas que complementan las medidas de tendencia central y dispersión. Ayudan a entender la forma de la distribución de los datos y a ubicar valores específicos dentro de esa distribución.

# MEDIDAS DE FORMA

## ASIMETRÍA

Grado de distribución de una distribución de datos.

- $\text{Asimetría} = 0 \rightarrow$  Distribución simétrica (como la campana de Gauss). También se conoce como: simetría.
- $\text{Asimetría} > 0 \rightarrow$  Sesgo a la derecha (cola más larga hacia la derecha). También se conoce como: asimetría positiva.
- $\text{Asimetría} < 0 \rightarrow$  Sesgo a la izquierda (cola más larga hacia la izquierda). También se conoce como: asimetría negativa.






# MEDIDAS DE FORMA

## CURTOSIS

Permite evaluar el grado de concentración de una distribución de datos en torno a su media. Determina si una distribución es más puntiaguda o aplanada.




- $\text{Curtosis} = 3 \rightarrow$  Distribución normal (mesocúrtica).
- $\text{Curtosis} > 3 \rightarrow$  Más alta y estrecha (leptocúrtica).
- $\text{Curtosis} < 3 \rightarrow$  Más plana (platicúrtica).

# MEDIDAS DE POSICIÓN

## CUARTILES

Dividen un conjunto de datos ordenado en cuatro partes iguales, cada una con el 25% de los datos.




- Q1 (primer cuartil): El 25% de los datos están por debajo de este valor.
  - Q2 (segundo cuartil): Corresponde a la mediana (50% de los datos).
  - Q3 (tercer cuartil): El 75% de los datos están por debajo de este valor.
- Se usan para analizar la dispersión y detectar valores atípicos (outliers).

# MEDIDAS DE POSICIÓN

## PERCENTILES

Dividen los datos en cien partes iguales, y son de las medidas más detalladas.



- P25: corresponde a Q1 (primer cuartil).
- P50: corresponde a la mediana.
- P75: corresponde a Q3.








# RETO DE PROGRAMACIÓN!!

Material del curso:

Link: [https://github.com/Liliana223/Fundamentos-de-la-bioestadistica-descriptiva?utm\\_source=canva&utm\\_medium=iframe](https://github.com/Liliana223/Fundamentos-de-la-bioestadistica-descriptiva?utm_source=canva&utm_medium=iframe)

O en Kaggle: <https://www.kaggle.com/datasets/samybaladram/palmers-penguin-dataset-extended?resource=download>



# RECURSOS ADICIONALES

dplyr: <https://nyu-cdsc.github.io/learningr/assets/data-transformation.pdf>

A ggplot2 Tutorial for Beautiful Plotting in R: <https://www.cedricscherer.com/2019/08/05/a-ggplot2-tutorial-for-beautiful-plotting-in-r/>

ggplot2: Elegant Graphics for Data Analysis (3e): <https://ggplot2-book.org/>

Fundamentos de Programación - BUCLES (Ciclos) EN PROGRAMACION: <https://www.youtube.com/watch?v=EbVT3XIf2TU>

Introducción a R. Bucles: <https://www.youtube.com/watch?v=w55TI908-Tw>

R for Data Science: <https://r4ds.had.co.nz/index.html>

R for Data Science Cookbook — Mark P. J. van der Loo & Yihui Xie (O'Reilly)





¡MUCHAS  
GRACIAS!

